

PROYECTO: BetAnalytics

Sistema de Apoyo a Decisiones en Apuestas
Deportivas (Premier League)

Profesor Osvaldo Ceballos

Integrantes: Matías Tobar

Sergio Soto

Alexis Mendoza

Sebastián Parada



1.El Terreno de Juego

Un entorno ideal para Data Science

La Premier League combina **altísima visibilidad global** con gran disponibilidad de datos públicos: calendarios, resultados y estadísticas históricas de cientos de partidos.

El mercado de apuestas añade una capa analítica: las cuotas expresan probabilidades implícitas, transformando el fútbol en un dominio con **decisiones, incertidumbre y variables medibles**.

Pregunta central

¿Podemos usar datos históricos para analizar resultados de Premier League de forma **objetiva y estructurada**?

Alcance del proyecto

- Liga: Premier League
- Fuente: FBref (scraping)
- Temporadas: 2017/18 — 2025/26



2. Justificación del Proyecto

¿Por qué es relevante resolver este problema?

Relevancia Académica

Aplica conceptos del curso: definición del problema, formulación de objetivos y estructuración metodológica.

Relevancia Analítica

Sustituye la intuición deportiva por análisis respaldado en **evidencia observable y reproducible**.

Relevancia Aplicada

La lógica del proyecto —estructurar decisiones bajo incertidumbre— es **transferible a otros dominios**.

Relevancia del Dominio

La Premier League ofrece continuidad temporal, alto volumen de observaciones y datos históricos públicos accesibles.

3. Definición del Problema

¿Es posible predecir el resultado de un partido de la Premier League combinando datos históricos de los equipos con las cuotas del mercado de apuestas, para identificar en qué partidos vale la pena apostar?



El modelo no busca "ganarle" a las casas: usa las cuotas como información adicional. Si el modelo y el mercado coinciden en que un equipo es favorito, esa señal combinada orienta la decisión de apostar.

1

¿Qué resultados vamos a predecir?

2

¿Qué datos vamos a usar?

3

¿Cómo sabremos si el modelo funciona?

4. Tipo de Problema



Tarea principal: Clasificación Supervisada

Cada partido se asigna a una **categoría de resultado**. El caso más completo es el **multiclasa 1X2** con tres salidas posibles.

Los otros mercados se formularon como problemas binarios (Sí o No / 1 o 0).

- Mercado Doble Oportunidad 1X (Local o Empate)
- Mercado Doble Oportunidad X2 (Visita o Empate):
- Mercado Home Clean Sheet (Arco Invicto Local):

5. Objetivos del Proyecto

Objetivo general

Formular una propuesta de Data Science para analizar resultados de la Premier League a partir de datos históricos de FBref.

Delimitar el problema

Definir liga, período (2017–2026) y variables objetivo: 1X2, Over/Under y BTTS

Construir el dataset

Extraer y limpiar ~3.000 partidos desde FBref con al menos 10 features por partido

Establecer variables de resultado

Definir las etiquetas (1, X, 2) y verificar su distribución en los datos.

Modelo base

Implementar un clasificador base de Regresión Logística. En etapas posteriores se comparará con modelos más complejos como Random Forest o XGBoost, según desempeño.

Validar contra el mercado

Comparar la probabilidad del modelo con la cuota real para encontrar partidos donde el mercado subestima o sobrevalora al equipo

6. Metodología: OSSEMN + CRISP-DM

Marcos de trabajo

Uso combinado de OSSEMN y CRISP-DM para asegurar el orden técnico.

Proceso seguido

1. Obtención
2. Exploración
3. Sanitización
4. Definición de variables
5. Modelado
6. Evaluación

7. Datos y construcción del dataset

Fuente

FBref + scraping histórico (temporadas 2017/18 a 2025/26).

Evolución

- Base cruda
- Base enriquecida (xG)
- Dataset Sanitizado v8

Registros

3420 totales (3349 partidos completos evaluables).

8. Sanitización y hallazgos de EDA

Revisión de nulos y ruido

Análisis exhaustivo de valores faltantes y anomalías.

Detección y remoción de leakage

Variables que anticipan el resultado fueron eliminadas.

Filtrado crítico

Exclusión de 71 fixtures futuros (`game_id = 0`).

Imputación y transformación


Imputación de faltantes y transformación de variables numéricas.

8. Sanitización y hallazgos de EDA

Tratamiento de Datos

Faltantes


- MAR (Missing at Random) en variables avanzadas como 'Expected Goals (xG)' y métricas arbitrales.



8. Sanitización y hallazgos de EDA

Manejo de Outliers e Inconsistencias


- Observamos que las métricas ofensivas (tiros, goles) tenían alta dispersión
- No eliminamos los outliers porque en fútbol contienen información vital (ej. un equipo con una racha ofensiva brutal).



8. Sanitización y hallazgos de EDA

Manejo de Outliers e Inconsistencias

- h_l5_xg y a_l5_xg (Expected Goals generados)
- h_l5_xga y a_l5_xga (Expected Goals concedidos al rival)
- h_l5_fls y a_l5_fls (Rachas de Faltas cometidas)
- referee_avg_cards_history (Promedio de tarjetas del árbitro)




8. Sanitización y hallazgos de EDA


Transformaciones y Variables Categóricas

- Aplicamos 'StandardScaler' a las variables numéricas normales. Rachas de Puntos (pts), Tiros totales (sh), Tiros a Puerta (sot), Goles reales (gf, ga), Tasa de Conversión (conv).
- Jerarquía y Contexto: home_elo, away_elo, home_rest (días de descanso), relegation_pressure (presión de descenso).
- Tratamiento de Categóricas decidimos usar una heurística avanzada calculamos el 'Elo Rating'.
- Intercambio por Expectativa

EL PROBLEMA: One-Hot Encoding
(Genera matrices dispersas llenas de ceros)




LA SOLUCIÓN: Elo Rating
(Convierte el "Nombre" en una Métrica Matemática Continua)



8. Sanitización y hallazgos de EDA


- Multicolinealidad



8. Sanitización y hallazgos de EDA

Relaciones (Multicolinealidad)


- En la matriz de correlación detectamos altísima colinealidad ($r > 0.8$) entre goles reales, tiros a puerta y xG.
- Eliminamos la redundancia manteniendo exclusivamente los 'Expected Goals (xG)' como mejor predictor ofensivo, logrando una matriz final con features independientes.



8. Sanitización y hallazgos de EDA

- Home rest vs away rest
- Volumen ofensivo vs Precision
- Consecuencia vs eficiencia
- Jerarquía vs estado de forma



DESPUES: Selección Estricta para el Modelo (27 Features)
Multicolinealidad reducida (menos bloques de correlación extrema)



8. Sanitización y hallazgos de EDA

Relación con el Target y Desbalanceo

- Usamos gráficos de distribución acumulada tipo Kolmogorov-Smirnov para aislar cómo se separan matemáticamente las variables clave frente al hecho de ganar o perder.
- La clase "Empate" es sumamente minoritaria (~23%).
- Optamos por utilizar modelos basados en árboles (robustamente naturales frente a desbalanceo) y atacar la predicción usando probabilidades umbrales ('predict_proba' > 57%) en lugar de clases duras.



9. Variables finales y reglas de validación

Variables de entrada (27 features pre-partido)

- Elo
- Descanso
- Forma reciente (5 partidos)
- xG/xGA agregados
- Contexto (derby, árbitro, descenso)

Regla de oro

El modelo solo ve información disponible antes del pitazo inicial.

10. Primer modelado y validación temporal

Modelos comparados

- Logistic Regression
- Random Forest
- HistGradientBoosting
- XGBoost


Validación estricta

- TimeSeriesSplit (5 splits)
- Holdout final (30% últimos partidos completos)

Enfoque

Se prioriza la robustez metodológica sobre los números inflados.


11. Resultados preliminares y gráficos defendibles



Resultados destacados (Holdout)

- Double Chance 1X: 68.2%
- Home Clean Sheet: 61%
- 1X2 (Multiclase): 46.2%

12. Aprendizajes y próximos pasos



Aprendizajes

La sanitización cambió la seriedad del proyecto; métricas más bajas pero mejor validadas son preferibles.

Próximos pasos

Refinar features, mejorar calibración y robustecer el backtesting.

SILBATAZO FINAL

¿Preguntas sobre la táctica?



Nota: Enfoque académico. No garantiza ganancias financieras.